3.4. Manual de uso del simulador

El objetivo de esta práctica es completar el simulador de planificadores que se ha implementado. Antes de comenzar la descripción del simulador y de las modificaciones propuestas en esta práctica, vamos a comentar brevemente cómo usarlo y sus principales funciones. En su estado actual (tal y como se entrega al alumno), el entorno es funcional y permite:

- Especificar el número de CPUs que serán simuladas
- Escoger qué planificador se usará. RR (round-robin) y SJF (primero el trabajo más corto) ya están implementados.
- Decidir si queremos la versión preemptive del planificador seleccionado
- Para el planificador round-robin, especificar el quanto de tiempo que se asignará a las tareas
- Seleccionar el periodo con el que se ejecutará el equilibrador de carga (además, se ejecutará siempre que una CPU esté ociosa)
- Generar gráficas de la planificación realizada en cada procesador, incluyendo información del tiempo de ejecución, tiempo bloqueado, tiempo en espera....

3.4.1. Ejecución y generación de diagramas

Una vez compilado (usando el *Makefile* entregado), podemos proceder a ejecutar el simulador. Para ver todas las opciones disponibles haremos lo siguiente:

```
$ ./schedsim -h
```

que devolverá un listado parecido al siguiente:

```
Usage: ./schedsim -i <input-file> [options]

List of options:
    -h: Displays this help message
    -n <cpus>: Sets number of CPUs for the simulato (default 1)r
    -m <nsteps>: Sets the maximum number of simulation steps (default 50)
    -s <scheduler>: Selects the scheduler for the simulation (default RR)
    -d: Turns on debug mode (default OFF)
    -p: Selects the preemptive version of SJF or PRIO (only if they are selected with -s)
    -t <msecs>: Selects the tick delay for the simulator (default 250)
    -q <quantum>: Set up the timeslice or quantum for the RR algorithm (default 3)
    -1 <period>: Set up the load balancing period (specified in simulation steps, default 5)
    -L: List available scheduling algorithms
```

Muchas de las opciones son autoexplicativas, y coinciden con las funcionalidades enumeradas anteriormente. A continuación, podemos realizar una primera simulación:

```
$ ./schedsim -i examples/example1.txt
```

La ejecución imprimirá por pantalla estadísticas de la ejecución de cada una de las tareas especificadas en el fichero examples/example1.txt y creará un fichero CPU_0.log que usaremos para generar un diagrama de la planificación. Para ello, usaremos la herramienta generate_gantt_chart en el directorio gantt-gplot:

```
$ cd ../gantt-gplot
$ ./generate_gantt_chart ../schedsim/CPU_0.log
```

Si todo ha ido bien en el directorio schedsim se habrá generado CPU_0.eps. La figura 3.1 muestra el resultado para ese ejemplo concreto. Vemos la progresión de cada una de las cuatro tareas que forman este ejemplo. Las partes azules indican tiempo de ejecución en CPU (de ahí que nunca solapen), la parte amarilla es tiempo de bloqueo (p.ej., simulando entrada/salida) y las zonas grises representan el tiempo en que una tarea estaba preparada para su ejecución pero la CPU estaba ocupada con otra tarea.

Podemos ejecutar el mismo ejemplo pero definiendo un sistema con 2 CPUs:

```
$ ./schedsim -i examples/example1.txt -n 2
```

La figura 3.2 muestra el resultado obtenido tras generar las diagramas.

Como podemos comprobar, al usar dos CPUs el tiempo total de ejecución pasa de 18 unidades de tiempo a 11. El reparto inicial de tareas a CPUs se hace de forma circular en función del número de la tarea: la tarea P1 a la CPU 0, la tarea P2 a la CPU 1, la tarea P3 a la CPU 0.... En este ejemplo el planificador no ha llevado a cabo ninguna migración, por lo que cada tarea finaliza en la misma CPU en la que comenzó su ejecución.

3.4.2. Descripción del perfil de ejecución de las tareas

Cada fila del fichero representa una nueva tarea que se simulará en el sistema. La primera columna representa el nombre de la tarea. La segunda columna, su prioridad. Posteriormente se indica el tiempo de llegada de la tarea al sistema (si es 0, se indica que la tarea está disponible desde el comienzo de la simulación). A partir de ahí encontramos el perfil de ejecución de cada tarea: el primer número indica el tiempo de ejecución de la primera ráfaga de CPU; luego, tiempo de espera (por E/S o similar). Y el patrón se repite hasta que la tarea finaliza (es decir, el mismo formato que se usa en la hoja de ejercicios).

Por ejemplo, en example1.txt se especifica que se crearán 4 tareas. La primera tarea, llamada P1 comienza su ejecución al principio de la simulación y tiene prioridad 1. Al comenzar, tratará de usar la CPU durante una unidad de tiempo. Posteriormente, se bloqueará durante 5 unidades de tiempo. Finalmente, volverá a requerir la CPU durante 4 unidades de tiempo y finalizará su ejecución.

Ejercicio 3: escribe un fichero de entrada que simule el conjunto de tareas del ejercicio 7 de la hoja de problemas. Ejecuta el simulador para resolver los apartados b,c y d de dicho problema.

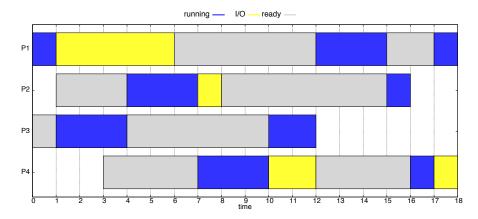


Figura 3.1: Resultado de simular el fichero example1.txt con una sola CPU

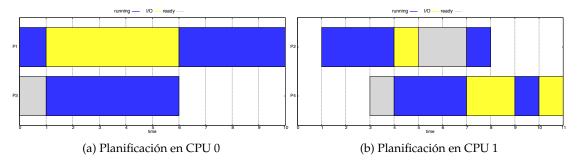


Figura 3.2: Simulación de example1.txt con 2 CPUs

3.5. Modelado del simulador

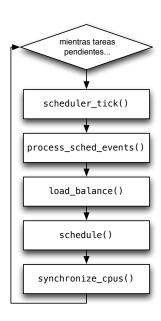


Figura 3.3: Diagrama de flujo del simulador

Hemos desarrollado un simulador de políticas de planificación basado en eventos. El código entregado facilita enormemente el desarrollo de nuevos planificadores, pues se encarga de la gestión de los eventos que van llegando al sistema (creación de tareas, migraciones, finalización de situación de bloqueo) e invoca al código de un planificador específico a través de una API muy sencilla. Por tanto, el trabajo del alumno se limitará a implementar dicha interfaz, que se detallará en la sección 3.5.4.

El simulador comienza creando un hilo por cada una de las CPUs que formen parte del sistema simulado. Tras una primera fase de inicialización de diferentes estructuras, cada hilo comienza a ejecutar la función sched_cpu(). La figura 3.3 ilustra el bucle de simulación presente en dicha función, que se ejecutará una y otra vez mientras queden tareas pendientes. El objetivo es simular fielmente lo que ocurriría en el planificador real en cada *tick* del reloj del sistema.

Como se observa en la figura, en cada paso de simulación (una iteración del bucle) se invocan cinco funciones, todas ellas ya implementadas en el fichero sched.c. En un planificador real, la llegada de una interrupción del *TIMER* del sistema (un *tick*) desencadenaría la ejecución de estas funciones.

En primer lugar se ejecuta la función **scheduler_tick()**. Esta función invoca a la función task_tick() del planificador en uso. Posteriormente comprueba si la tarea en ejecución termina en este ciclo su ráfaga de CPU (es decir, si se va a bloquear por E/S o finaliza completamente su ejecución). Si es así, pasa la tarea al estado SLEEP para que no sea considerada en la siguiente decisión de planificación o informa de la finalización de la tarea (si es el caso).

Posteriormente se invoca la función **process_sched_events()** que procesa los eventos pendientes en esta CPU (un evento es la entrada de una nueva tarea en el sistema o una tarea saliendo de su situación de bloqueo). En caso de que haya un evento, se invoca a la función enqueue_task() del planificador usado para que introduzca la tarea correspondiente en la *run queue* (cola de tareas listas para ejecutar asociadas a una CPU).

En tercer lugar, se llama a la función **load_balance()** que comprobará si es necesario realizar un equilibrado de carga. Si es así, comenzará una migración de tareas de la CPU con más carga a la CPU con menos carga. Este proceso requiere una sincronización *delicada* entre hilos, por lo que postergamos su discusión a la sección 3.5.1.

Tras el balanceo de carga, se invoca a la función **schedule()** que, en caso de que sea necesario tomar una decisión de planificación (esto es, si la llamada a scheduler_tick() marcó la cola de ejecución para replanificación) procede a escoger la tarea que pasará a ocupar la CPU. Para ello, invoca la función pick_next_task() del planificador en uso, que devolverá la tarea escogida de acuerdo con el criterio de planificación. En ese instante, se realiza el cambio de contexto.

Finalmente se produce la llamada a **synchronize_cpus()**, en la que el hilo de cada CPU comprueba si ya ha terminado el trabajo que tenía asignado. Nótese que, dado que es posible realizar migraciones de tareas, todos los hilos que simulan cada CPU deben continuar iterando hasta que todas las CPUs hayan terminado su trabajo; es posible que la CPU *i-ésima* no tenga ninguna tarea asignada en el instante t, pero que se produzca un equilibrado de carga que le asigne una (o más) tareas en el instante t+1. Esto exige una sincronización entre todos los hilos del simulador para determinar cuándo se ha finalizado realmente la simulación. Esta sincronización se realiza mediante una *barrera*. En el código entregado se utiliza una barrera POSIX (tipo pthread_barrier_t), que se basa en el uso de la función pthread_barrier_wait(). Uno de los puntos de la parte obligatoria será implementar este mecanismo utilizando cerrojos y variables condicionales.

3.5.1. Equilibrado de carga

En un ciclo de simulación sin equilibrado de carga, cada CPU simulada (esto es, cada hilo de ejecución en nuestro simulador) consultará (y modificará si procede) únicamente su propia *run queue* a la hora de tomar una decisión de planificación. Sin embargo, durante el proceso de equilibrado de carga, es posible que el hilo de la CPU0 deba acceder a la *run queue* de la CPU1, lo que convierte a estas colas en secciones críticas que debemos proteger con un cerrojo.

Examinando con detalle el código de la función <code>load_balance()</code>, comprobamos que puede haber dos hilos (el de la CPU con mayor carga y el de la CPU con menor carga) que van a tratar de conseguir los cerrojos de sus respectivas *run queues*. Dependiendo del orden en que se realice la adquisición de dichos cerrojos, podemos encontrarnos con una situación de interbloqueo.

Para evitar esa situación, se establece un orden en el que deben adquirirse los cerrojos. Esa estrategia está implementada en la función double_lock_rq: hay que empezar por adquirir los cerrojos de las CPUs con IDs mayores. En algún caso, eso puede exigir liberar temporalmente el cerrojo propio para volver a adquirirlos en el orden establecido.

Ejercicio 4: La solución adoptada para evitar interbloqueos en el equilibrador de carga se puede utilizar para resolver el problema de *los filósofos*. Implementa un código que modele dicho problema creando 5 hilos que representarán a los 5 filósofos. Cada uno de ellos se limitará a *pensar* (que se simulará mediante a una llamada a *sleep()* con un tiempo aleatorio) y posteriormente *comer*. Antes de comer, deberán coger dos tenedores: el de su derecha y el de su izquierda (no necesariamente en ese orden...). Posteriormente, dejará los tenedores, dormirá y volverá a pensar. El acto de coger un tenedor se modelará con el intento de adquirir un cerrojo.

3.5.2. Estructuras de datos relevantes

Cada una de las CPUs simuladas dispone de su propia *run queue*, una cola donde almacena las tareas asignadas a esa CPU y que irán ejecutándose siguiendo la estrategia de planificación concreta. El tipo de datos empleado para una *run queue* es:

El primer campo, tasks, es la lista de tareas en espera de poder usar la CPU. En la sección 3.5.3 se explica el API para gestionar esta lista. El campo cur_task es un puntero a la tarea que actualmente está en ejecución en la CPU asociada a esta *run queue*. Es importante tener en cuenta que esta tarea (la actual) no está incluida en la lista de tareas del campo anterior.

Cada run queue tiene su propia idle_task que tomará la CPU cuando no haya ninguna tarea runnable, esto es, en disposición de ejecutarse. El flag need_resched deberá ponerse a TRUE cuando se deba proceder a replanificar (elegir una nueva tarea para su ejecución). nr_runnable es el contador del número de tareas actualmente en la cola.

next_load_balancing especifica en qué instante de tiempo (del futuro) debe estudiarse un nuevo equilibrado de carga. El campo rq_cs_data es un puntero genérico (void*) que permite que el algoritmo de planificación escogido apunte a una estructura privada con los campos que desee. En la versión del simulador que se proporciona, ninguna estrategia de planificación hace uso de datos privados en la *run queue*, por lo que este campo se pone a NULL. Por último, el campo lock es el cerrojo que usaremos para acceder en exclusiva a los diferentes campos de esta estructura.

Otro tipo de datos relevante para la implementación de nuevos algoritmos de planificación es el de una tarea⁴: task_t.

```
typedef struct{
                              /\star Internal ID for the task\star/
   int task_id;
   char task_name[MAX_TASK_NAME];
   exec_profile_t task_profile; /* Task behavior */
   int prio;
   task_state_t state;
                          /\star CPU where the task ran last time \star/
   int last_cpu;
   complete till blocking or exiting */
                          /* Node for the global task list */
   list_node_t ts_links;
   list_node_t rq_links;
                           /* Node for the RQ list */
   bool on_rq;
                           /* Marker to check if the task is on the rq or not */
   unsigned long flags;
                          /* generic flags field */
   data if needed */
/* Global statistics */
                          /* CPU time */    /* Elapsed time since the application entered the
   int user_time;
   int real_time;
      svstem */
   int sys_time;
                          /\star For now this time reflects the time the thread
                           spends doing IO */
   slist_t sched_regs;
                          /* Linked list to keep track of the sched log registers
                                  (track state changes for later use) */
}task_t;
```

Muchos de los campos de esta estructura tienen un carácter estadístico y son autoexplicativos. Asimismo, la mayoría de los campos se utilizan únicamente en el fichero sched.c que

⁴Durante esta práctica usamos siempre el término tarea para referirnos a las entidades que serán simuladas; usamos hilo para referirnos a hilos reales que usamos para implementar el simulador. El tipo de datos task_t es parte de lo que podría contener el Bloque de Control de Hilo de un sistema operativo real.

se da completamente implementado. Los campos más reseñables de cara a la realización de la práctica son:

- prio es la prioridad de la tarea, que puede usarse para determinar cuál es la siguiente tarea que debe acceder a la CPU.
- runnable_ticks_left indica cuántos *ticks* restan para que finalice la ráfaga de CPU actual. La inicialización de este campo se realiza en sched. c. Este campo puede necesitarse para escoger la siguiente tarea a ejecutar: así ocurre en el algoritmo SJF.
- on_rq es un booleano que el planificador pone a TRUE cuando la tarea esté en la run queue (es decir, no está en ejecución ni bloqueada).
- flags puede usarse para anotar cualquier situación que consideremos oportuna para el planificador. Actualmente hay definidos dos *flags* (en el fichero sched.h):
 - TF_IDLE_TASK que nos permite saber rápidamente si una tarea es la tarea idle
 - TF_INSERT_FRONT que utiliza la política SJF para introducir una tarea al principio de la lista en lugar de al final en determinadas situaciones.
- tcs_data es un puntero genérico (void*) que permite que el algoritmo de planificacion activo apunte a una estructura con campos privados de la tarea para uso interno del algoritmo de planificación. En la versión inicial del simulador, solo el algoritmo RR hace uso de este puntero (ver fichero sched_rr.c); para el resto de políticas de planificación este campo se pone a NULL.

3.5.3. Uso de listas doblemente enlazadas

En el fichero slist.h se define el tipo slist_t que permite la creación de listas enlazadas de cualquier tipo de elementos. Como se indicó anteriormente, una *run queue* posee, entre otras cosas, una lista de tareas (estructuras task_t) que el planificador deberá gestionar. El API proporcionado para interaccionar con estas listas es el siguiente:

```
void init_slist (slist_t* slist, size_t node_offset);
void insert_slist ( slist_t* slist,void* elem);
void insert_slist_head ( slist_t* slist, void* elem);
void remove_slist ( slist_t* slist,void* elem);
void* head_slist ( slist_t* slist);
void* tail_slist ( slist_t* slist);
void* next_slist ( slist_t* slist,void* elem);
void* prev_slist ( slist_t* slist, void* elem);
void insert_after_slist(slist_t* slist, void *object, void *nobject);
void insert_before_slist(slist_t* slist, void *object, void *nobject);
int is_empty_slist(slist_t* slist);
int size slist(slist t* slist);
void sorted_insert_slist(slist_t* slist, void* object, int ascending, int (*compare)(
    void*, void*));
void sorted_insert_slist_front(slist_t* slist, void* object, int ascending, int (*
    compare) (void*, void*));
void sort_slist(slist_t* slist, int ascending, int (*compare)(void*,void*));
```

Nuevamente, la mayoría de las funciones son autoexplicativas. A modo de ejemplo comentamos algunas de las funciones más utilizadas:

• head_slist () devuelve el primer elemento de la lista (pero no lo saca de la lista).

- tail_slist() devuelve el último elemento de la lista (pero no lo saca de la lista).
- remove_slist() elimina el elemento elem de la lista.
- insert_slist() inserta el elemento elem al final de la lista.
- sorted_insert_slist() realiza una inserción ordenada del elemento object al final de la lista. La función de comparación que se empleará es el cuarto argumento de la función. Se puede consultar un uso de esta función en el fichero sched_sjf.c.

3.5.4. Implementación de un nuevo planificador

Ya estamos en disposición de implementar un nuevo planificador. Para ello basta implementar las funciones de la interfaz de un planificador (estructura sched_class_t definida en sched.h). Dicha interfaz consta de las siguientes operaciones:

```
typedef struct sched_class {
   int (*sched_init) (void);
   void (*sched_destroy) (void);
   int (*task_new) (task_t* t);
   void (*task_free) (task_t* t);
   task_t* (*pick_next_task) (runqueue_t* rq,int cpu);
   void (*enqueue_task) (task_t* t,int cpu, int runnable);
   void (*task_tick) (runqueue_t* rq,int cpu);
   task_t* (*steal_task) (runqueue_t* rq,int cpu);
}sched_class_t;
```

Las operaciones pick_next_task (), enqueue_task () y steal_task () se han de implementar siempre en todos los algoritmos de planificación. El resto de operaciones sólo se implementan en algunos casos que detallaremos a continuación. Describimos ahora sucintamente qué deben hacer estas funciones:

- sched_init() y sched_destroy() son respectivamente las operaciones de inicialización y destrucción de un planificador y se invocan una sola vez durante la simulación. Estas operaciones han de implementarse solamente en el caso de que el planificador necesite almacenar información extra en la run queue de cada CPU, es decir, usando campos que no estén definidos en runqueue_t. En tal caso, el planificador hará uso del puntero genérico rq_cs_data, campo de runqueue_t, que se inicializará adecuadamente en sched_init() y cuya memoria se liberará en sched_destroy(). En la versión básica del simulador que se proporciona ninguna política de planificación implementa estas funciones, al no precisar de campos extra en la run queue. No obstante, se podría hacer uso de esta característica en alguna ampliación propuesta como parte extra de la práctica.
- task_new() y task_free() se invocan al crear una tarea y al destruirla, respectivamente. Estas operaciones han de implementarse solamente si el planificador necesita mantener campos extra de cada tarea; es decir, campos no definidos en la estructura task_t. El planificador RR es el único algoritmo del simulador que implementa estas operaciones, ya que reserva una estructura con campos extra por cada tarea en task_new() (consultar fichero sched_rr.c). Como se comentó previamente, el puntero genérico tcs_data de task_t sirve para apuntar a la estructura con campos extra. Esto permite recuperar esta estructura en las operaciones de la interfaz del planificador.
- pick_next_task() se invocará cuando se deba escoger una nueva tarea para ejecutar en la CPU. Seleccionará una tarea de la *run queue*, la eliminará de la *run queue* y devolverá dicha tarea. Es la función que realmente lleva a cabo la política de planificación deseada.

- enqueue_task() se invocará cada vez que debamos encolar una tarea en la *run queue* de una CPU, bien porque acaba de crearse, porque sale de un bloqueo o porque se ha migrado desde otra *run queue*.
- task_tick() se invocará en cada tick de simulación (iteración del bucle principal). En políticas de planificación expropiativas, como RR, se usa esta operación para actualizar alguna métrica de la tarea, que resulta relevante para determinar cuándo se debe producir una replanificación.
- steal_task() se invocará cuando se lleve a cabo una migración que exija robar una tarea de la run queue rq. La tarea escogida se sacará de la run queue y se devolverá como argumento de salida de la función.

Para implementar un nuevo algoritmo de planificación debemos implementar el subconjunto de operaciones necesarias de la interfaz sched_class_t en un nuevo fichero .c. Por convenio, el nombre de la función que implementa cada operación de la interfaz contendrá un sufijo con el nombre en minúscula del algoritmo de planificación precedido por "_". Así por ejemplo, la función pick_next_task_rr() implementa la operación pick_next_task del algoritmo RR.

Una vez se hayan definido estas operaciones, se ha de especificar en el mismo fichero .c la relación entre cada operación de la interfaz y la función que la implementa. Para ello, basta con definir una variable de tipo sched_class_t inicializada adecuadamente. Por ejemplo, la variable rr_sched, definida en sched_rr.c, define el planificador RR:

```
sched_class_t rr_sched={
    .task_new=task_new_rr,
    .task_free=task_free_rr,
    .pick_next_task=pick_next_task_rr,
    .enqueue_task=enqueue_task_rr,
    .task_tick=task_tick_rr,
    .steal_task=steal_task_rr
};
```

Por último, para acabar con la definición del nuevo planificador, será preciso añadir una nueva entrada en la estructura available_schedulers, (sched.h), así como en el tipo enumerado definido justo antes de dicha variable. El contenido actual de la variable es:

Para registrar un nuevo planificador en el simulador bastaría añadir una nueva línea indicando la variable de tipo $sched_class_t$ creada en el nuevo fichero . c con la implementación del planificador.

En las secciones anteriores se mostraba el contenido completo de dos estructuras de datos relevantes en el simulador. Sin embargo, a la hora de implementar una nueva política de planificación, los únicos campos de las estructuras runqueue_t y task_t que se deben modificar son rq->tasks, rq->need_resched y tsk->flags. Es importante notar que el cerrojo de la *run queue* no está en esta lista: en el momento de invocar a las funciones de un planificador específico, el cerrojo de la *run queue* ya se ha adquirido si era necesario, por lo que no debemos preocuparnos de ese aspecto durante la implementación.

3.6. Parte obligatoria

Como parte obligatoria de esta práctica se deberán realizar las siguientes modificaciones en el simulador:

- Crear un planificador FCFS (First Come First Served): el trabajo que lleve más tiempo esperando será el siguiente en ocupar la CPU. A la hora de ceder tareas a otra run queue se escogerá la última tarea de la cola (la que lleva menos tiempo esperando). Crear un fichero sched_fcfs.c en el que se implementarán todas las operaciones de la interfaz sched_class_t que el alumno considere necesarias para construir el planificador FCFS.
- Crear un planificador **expropiativo** basado en prioridades. El único criterio de planificación será la prioridad asignada a cada tarea de forma estática en el fichero de configuración. Para la implementación de este planificador es aconsejable fijarse en la estrategia de implementación del algoritmo SJF.⁵ En caso de migración, se cederá la tarea menos prioritaria de las que estén en la cola. Crear un fichero sched_prio.c en el que se implementarán todas las operaciones necesarias de la interfaz sched_class_t.
- Implementar una barrera de sincronización usando cerrojos y variables condicionales. Completar el fichero barrier.c (funciones sys_barrier_init(), sys_barrier_destroy() y sys_barrier_wait() de la rama #else). Para probar esta funcionalidad, hay que modificar el *Makefile* para evitar que se declare la macro POSIX_BARRIER.
- Escribir un script shell que no reciba ningún argumento, pero que pregunte al usuario dos datos:
 - Qué fichero de ejemplo desea simular. Se comprobará que el fichero existe y es un fichero regular. En caso contrario, se informará al usuario y se volverá a preguntar por el nombre
 - Número máximo de CPUs que se desean usar en la simulación. El número introducido no deberá ser mayor que 8. Si es mayor, se informará al usuario del error y se le volverá a preguntar el número de CPUs.

A continuación, se creará un directorio resultados y se ejecutará el simulador para cada uno de los 4 planificadores disponibles, y para todas las CPUs entre 1 y el número escogido por el usuario. Todos los resultados se irán almacenando (sin sobre-escribirse) en el directorio resultados. Finalmente, se generarán las gráficas para todos los ficheros de salida, almacenándose también en el mismo directorio.

⁵Notese que la variable global preemptive_scheduler que se usa en la implementación de SJF se pone a 1 al especificar la opción ¬p de la línea de comando al invocar el simulador.

17

El pseudo-código de la parte central del *script* sería:

```
maxCPUs = valor introducido por usuario

foreach nameSched in listaDeSchedulersDisponibles
do
    for cpus = 1 to maxCPUs
    do
        ./sched-sim -n cpus -i .....
    for i=1 to cpus
    do
        mover CPU_$i.log a results/nameSched-CPU-$i.log
        generar gráfica
    done
    done
done
```